

项目执行文件（Phase 1：高精度物理概率模型构建）v5.5

版本记录

- v5.5：引入“数据量优化策略”（分片下载+断点续传）与“时间间隔统一协议”（3小时间隔对齐）。
- v5.4：引入“双重验收标准”（校准度+锐度）与“时间墙隔离协议”，彻底封堵PIT假均匀与数据泄漏风险。
- v5.3：引入“模型训练鲁棒性协议”（三级降级）与“季节非平稳性处理协议”（季度分桶）。
- v5.2：引入“空间-物理双重修正协议”（双线性插值+高程修正）。
- v5.1：确立“数据分辨率一致性协议”（强制降频对齐）。
- v5.0：明确数据架构与核心流程。

1. 数据架构模块（核心更新）

1.1 数据源与获取方式

- 真实值**：Wunderground API（JSON格式），按 UTC 时间戳拉取，存储为 Parquet/CSV。
- 预报场**：GEFS Reforecast（GRIB2格式），原始数据解析为 5 维数组（init_time, lead_time, ensemble_member, lat, lon）。

1.2 时间对齐与分辨率协议

核心原则：确保训练与预测的特征提取逻辑严格一致。

1.2.1 时间窗口切片

- 将 UTC 时间转换为站点当地时间。
- 界定自然日窗口（00:00 - 23:59 当地时间）。
- 提取落在该窗口内的 GEFS 预报场数据。

1.2.2 时间间隔统一协议（v5.5 核心）

- 现状差异**：Reforecast 与实时 GEFS 均为 3 小时间隔。
- 执行规范**：在预测阶段，必须对实时 GEFS 数据执行**强制降频**，仅选取 00Z, 06Z, 12Z, 18Z 时刻，丢弃中间时刻，确保与训练数据分布一致。

2. 空间-物理双重修正协议 (v5.2 核心)

在将网格数据转化为站点特征时，必须执行物理修正以消除系统性偏差。

2.1 空间插值策略

- **决策**：强制使用**双线性插值**。
- **禁止**：严禁使用最近邻插值，以避免格点边界跳变误差。

2.2 高程气温递减率修正

- **问题**：模式地形与站点海拔差异导致系统性温度偏差。
- **修正公式**： $T_{\text{station}} = T_{\text{model}} + (H_{\text{station}} - H_{\text{model}}) \times \Gamma$
- **参数**：采用标准气温垂直递减率 $\Gamma = 0.0065 \text{ K/m}$ 。
- **工程实现**：

```
1  # 站点元数据必须包含精确海拔
2  STATION_META = {"ZSPD": {"lat": 31.15, "lon": 121.80, "elevation": 4.
3
4  # 提取特征时应用修正
5  def extract_features(gefs_ds, station):
6      # 1. 双线性插值
7      t2m_interp = gefs_ds['t2m'].interp(lat=station['lat'], lon=station['lon'])
8      # 2. 高程修正
9      model_elev = gefs_ds['orog'].interp(...).values
10     correction = (station['elevation'] - model_elev) * 0.0065
11     return t2m_interp + correction
```

3. 模型训练模块 (Skew-EMOS)

3.1 季节非平稳性处理：季度分桶 (v5.3)

- **策略**：拒绝全历史统一训练，采用**季度分桶**。
- **划分**：
 - **DJF 冬**: 12, 1, 2 月
 - **MAM 春**: 3, 4, 5 月
 - **JJA 夏**: 6, 7, 8 月
 - **SON 秋**: 9, 10, 11 月
- **产出**：每个站点生成 4 个独立的模型参数文件（如 ZSPD_DJF.pkl）。

3.2 数值优化鲁棒性协议：三级降级 (v5.3)

针对偏态/截断 EMOS 拟合过程中的数值不稳定性，执行自动降级：

- Level 1：截断正态 EMOS（全参数）**
 - 采用截断正态分布，利用解析解计算 CRPS，避免数值积分陷阱。
 - 使用标准正态 EMOS 参数作为热启动初始值。
- Level 2：标准高斯 EMOS（去偏态）**
 - 若 Level 1 不收敛，自动去除偏度参数，退化为标准高斯 EMOS。
- Level 3：气候学分布（兜底）**
 - 若 Level 2 失败，输出历史同期的均值与方差，确保系统永不崩溃。

4. 验证引擎与验收交付（v5.4 核心）

4.1 双重验收标准：校准度 + 锐度

为防止模型通过“盲目放大方差”刷分，确立双重约束机制。

维度	指标	验收阈值	目的
校准度	PIT K-S P-value	> 0.05	确保概率分布统计合理
	80% PI Coverage	78% - 82%	确保区间命中率真实
锐度	MPIW Ratio	< 0.9 相对于气候学	强制模型“有用”， 杜绝假均匀

MPIW Mean Prediction Interval Width:
$$\text{MPIW}_{80} = \frac{1}{N} \sum (q_{90} - q_{10})$$

验收规则：模型 MPIW 必须显著小于气候学 MPIW（至少窄 10%），否则判定为无效模型。

4.2 时间墙隔离协议

- 禁止**：严禁使用 K-Fold 交叉验证（防止时间序列泄漏）。
- 策略**：采用 **Rolling-Origin** 留出法 **验证**。
- 数据划分**：
 - 训练集**：2021年1月1日 - 2024年12月31日（用于拟合 EMOS 参数）。
 - 验证集**：2025年1月1日 - 2025年12月31日（仅用于计算 CRPS/PIT/MPIW）。
- 铁律**：训练阶段严禁访问验证集数据。

4.3 验证引擎代码逻辑

```
1 def validate_model_performance(model, test_data_2025):
```

```
2      # 1. 预测
3      params = model.predict(test_data_2025.features)
4
5      # 2. 校准度检查
6      pit = calc_pit(params, test_data_2025.truth)
7      ks_p = kstest(pit, 'uniform').pvalue
8      coverage = calc_coverage(params, test_data_2025.truth, level=0.8)
9
10     # 3. 锐度检查 (关键)
11     mpiw_model = calc_mpiw(params, level=0.8)
12     mpiw_clim = get_climatology_mpiw(test_data_2025.station)
13     sharpness_ratio = mpiw_model / mpiw_clim
14
15     # 4. 综合判决
16     passed = (ks_p > 0.05) and (0.78 < coverage < 0.82) and (sharpnes
17     return {"status": "PASS" if passed else "FAIL", "details": {...}}
```

5. 数据量优化策略 (v5.5 新增)

5.1 分片下载策略

由于 GEFS reforecast 数据量较大 (约 315GB/20年) , 采用分片下载策略 :

- 按年份分片 : 每年独立下载 , 避免单次下载过大文件。
- 按成员分片 : 每个成员单独下载 , 便于并行处理。
- 按时次分片 : 仅下载目标日所需的 24h 覆盖 (如 f00, f03, f06, ..., f24) 。

5.2 分段处理机制

- 内存分段 : 使用 `xarray.open_mfdataset` 分块加载 , 避免内存溢出。
- 时间分段 : 按自然日分段处理 , 确保数据一致性。

5.3 断点续传机制

- 文件状态记录 : 维护下载状态文件 , 记录已下载的年份、成员、时次。
- 失败重试 : 网络中断时自动从断点续传。
- 校验机制 : 下载完成后验证文件完整性 (MD5 校验) 。

5.4 数据缓存策略

- 本地缓存 : 下载后立即裁剪并删除原始全球文件 , 只保留裁剪后的区域数据。
 - 增量更新 : 仅下载新增数据 , 避免重复下载。
-

6. 单元测试规范

6.1 插值测试

- 断言高程修正后温度变化方向符合物理规律（站点低于模式点应升温）。

6.2 降级测试

- 输入全零方差病态数据，断言训练流程返回 Level 3 气候模型且不抛出异常。

6.3 分辨率测试

- 输入 3 小时模拟数据，断言特征提取模块仅输出 6 小时间隔的结果。

6.4 数据量测试

- 模拟大文件下载失败，断言断点续传机制正常工作。

7. 总结

v5.5 版本标志着 Phase 1 技术方案的完全闭环：

- 数据层**：通过分辨率对齐与物理修正，消除了时空维度的系统性误差。
- 模型层**：通过三级降级与季度分桶，解决了数值稳定性与季节非平稳性问题。
- 验证层**：通过双重验收标准与时间墙隔离，确保了模型的概率正确性与商业价值。
- 工程层**：通过分片下载与断点续传，解决了大规模数据处理的可行性问题。

注:本文部分内容由AI生成,无法确保真实准确,仅供参考